# Introducción a Bases de Datos (BD) Biológicas Curso de Bioinformática

Luis E. Garreta U

Pontificia Universidad Javeriana – Cali Facultad de Ingeniería - Carrera de Biología

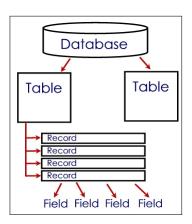
6 de agosto de 2018



## Conceptos de BD

#### Qué es una Bases de Datos ?

- ► Una BD es una colección estructurada de información.
- La información o datos están organizados en **Tablas**.
- Las unidades básicas de una tabla son llamadas registros.
- Cada registro consiste de varios campos.
- Cada campo representa una información de ese registro.
- Cada registro tiene un identificador único.



Conceptos BD Biológicas Acceso Tipos

#### Ejemplo: Base de Datos en forma de tabla

- ► Una BD se puede ver como una tabla donde:
  - ► Las filas corresponden a los registros
  - ► Las columnas corresponden a los campos

Campos           Field Record         Name         Length         Sequence         Enzyme           QA001         MTGA         243         MYQWI         yes           QA002         Ribosomal protein L9         267         MAAPV         no				
	Name	Length	Sequence	Enzyme
QA001	MTGA	243	MYQWI	yes
QA002		267	MAAPV	no
QA003	Flagellin	374	GSSIL	no
QA004	GDPMH	157	MFLRQ	yes



► Número de Acceso (Accession Number): Son los identificadores únicos de cada registro de la BD



#### Organización de los datos en BD

- ► Archivos de texto planos
- ► BDs relacionales

#### Archivos de texto Planos

- Originalmente, todas las bases de datos utilizaban un formato de archivo de texto plano, sin formato.
- No contiene instrucciones ocultas para las computadoras.
- No se puede realizar búsquedas inteligentes por campos o por registros.

LOCUS	AAL93223 348 aa linear VRT 02-0CT-2003					
DEFINITION	NADH dehydrogenase subunit 2 [Ictalurus punctatus].					
ACCESSION	AAL93223					
VERSION	AAL93223.1 GI:19702261					
DBSOURCE	accession AF482987.1					
KEYWORDS						
SOURCE	mitochondrion Ictalurus punctatus (channel catfish)					
ORGANISH	I Ictalurus punctatus					
	Eukaryota; Metazoa; Chordata; Craniata; Vertebrata; Euteleostomi;					
	Actinoptervqii; Neoptervqii; Teleostei; Ostariophysi; Siluriformes;					
	Ictaluridae; Ictalurus.					
REFERENCE	1 (residues 1 to 348)					
AUTHORS	Waldbieser, G.C., Bilodeau, A.L. and Monneman, D.J.					
TITLE	Complete sequence and characterization of the channel catfish					
	mitochondrial genome					
COMMENT	Method: conceptual translation supplied by author.					
ORIGIN						
1	mspyvitill sslglgtalt fmsshwllaw mgleintlai lplmaqhhhp raveattkyf					
61	laqaaaaati lfastinawt tgewniycls hpaatilitm alalkvglap vhfwmppvmq					
121	gltlttglim atwoklapfa liiqmapfth plllttlgll svfiggwggl nqtqlrkila					
181	yssiahlgwm iivtqykpql tvlvlityii mtsatfltfk lmattkintl amswakvpti					
241	tamaalalis iggippitgf mpkwliiqel tmqglpitat mmtlsalisi yfylricyam					
301	tltispntnn ssapwrlqnt qataplatlm imtllllplt plaqtltn					
11						

#### **BDs** Relacionales

- ► Contienen tanto los registros de datos como también las conexiones visibles e invisibles entre ellos.
- Esta organización facilitar la ejecución de las consultas complejas.

Table	for	n	novie
IID.			TIME

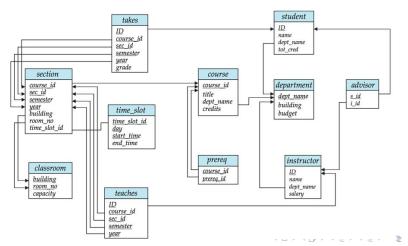
ID	Title	Year	Director	
movie001	The man who shot Liberty Valance	1962	per001	•
movie003	The Grapes of Wrath	1940	per001	
movie003	Pulp Fiction	1994	per002	
movie004	The matrix	1999	per003	
movie005	Cidade de Deus	2002	per004	
relation				

	ID	Name	Surname	Origin
•	per001	John	Ford	USA
	per002	Quentin	Tarantino	USA
	per003		Wachowski	USA
	per004	Fernando	Mirelles	Brazil



#### Esquema de una BD Relacional

► Muchas tablas, con muchos registros, con muchos campos y muchas conexiones



## BDs Biológicas

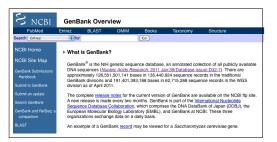
onceptos BD Biológicas Acceso Tipos

#### Tipos de Secuencias en las BDs Biológicas

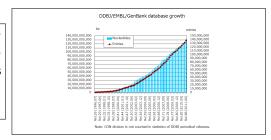
- ► Secuencias de ADN, ARN, Proteínas, b:
  - ► **Nucleótidos**: orígenes, secuencias codificantes, genes, etc.
  - Aminoácidos: proteínas
  - ► Estructuras 3D: estruc
  - Genomas: secuencias completas para organismos
  - ► Publicaciones: artículos científicos
- Información adicional relacionada con las secuencias (Datos derivados):
  - ► Expresión asociada
  - Anotaciones funcionales
  - Relaciones entre secuencias



#### Crecimiento de las BDs Biólogicas



Existen approximadamente 286,730,369,256 registros de secuencias en las divisiones tradicionales del GenBank (2011).



#### Crecimiento por Divisiones del GenBank

#### Medida en pares de bases de nucleótidos (bp)

Table 1. Growth of GenBank Divisions (nucleotide base-pairs)

Division	Description	Release 173 (8/2009)	Release 179 (8/2010)	Increase (%)
TSA	Transcriptome shotgun data	39 829 979	398 676 845	900.9
ENV	Environmental samples	1 091 072 890	1 723 286 428	57.9
PAT	Patented sequences	5 592 927 651	8 519 294 473	52.3
BCT	Bacteria	4 107 328 206	5 333 010 385	29.8
VRL	Viruses	779 481 462	970 125 245	24.5
PHG	Phages	36 100 172	43 456 808	20.4
MAM	Other mammals	576 977 646	679 274 390	17.7
INV	Invertebrates	1 734 996 371	2 036 240 836	17.4
WGS	WGS data	148 165 117 763	169 253 846 128	14.2
GSS	Genome survey sequences	16 738 219 857	18 442 479 673	10.2
PLN	Plants	3 695 552 256	4 038 424 961	9.3
SYN	Synthetic	131 361 806	142 548 355	8.5
VRT	Other vertebrates	2 366 300 257	2 533 789 261	7.1
EST	ESTs	34 522 977 161	36 803 930 321	6.6
HTC	High-throughput cDNA	636 472 189	659 355 057	3.6
PRI	Primates	5 751 413 009	5 943 029 356	3.3
ROD	Rodents	4 206 718 960	4 298 354 944	2.2
HTG	High-throughput genomic	23 895 733 886	24 276 862 305	1.6
UNA	Unannotated	119 348	120 289	0.8
STS	Sequence tagged sites	629 573 650	634 263 196	0.7
TOTAL	All GenBank sequences	254 698 274 519	286 730 369 256	12.6

#### Registros de un BD Biológica

► Ejemplo de un registro en formato GenBank

```
LOCUS
           AAL93223
                                     348 aa
                                                       linear
                                                                VRT 02-0CT-2003
DEFINITION
           NADH dehydrogenase subunit 2 [Ictalurus punctatus].
ACCESSION
            AAL93223
VERSION
           AAL93223.1 GT:19702261
DBSOURCE
            accession AF482987.1
KEYWORDS
           mitochondrion Ictalurus punctatus (channel catfish)
SOURCE
 ORGANISM Ictalurus punctatus
            Eukaryota; Metazoa; Chordata; Craniata; Vertebrata; Euteleostomi;
            Actinopterygii; Neopterygii; Teleostei; Ostariophysi; Siluriformes;
            Ictaluridae: Ictalurus.
REFERENCE
            1 (residues 1 to 348)
 AUTHORS
           Waldbieser, G.C., Bilodeau, A.L. and Nonneman, D.J.
 TITLE
            Complete sequence and characterization of the channel catfish
            mitochondrial genome
COMMENT
            Method: conceptual translation supplied by author.
ORIGIN
        l mspyvitill sslqlgtalt fmsshwllaw mgleintlai lplmaqhhhp raveattkyf
       61 lagaaaaati lfastinawt tgewniycls hpaatilitm alalkvglap vhfwmppvmg
      121 gltlttglim atwcklapfa liigmapfth plllttlgll svfiggwggl ngtglrkila
      181 yssiahlqwm iivtqykpql tvlvlityii mtsatfltfk lmattkintl amswakvpti
      241 tamaalalis lgglppltgf mpkwlilgel tmgglpltat mmtlsalisl yfylricyam
      301 tltispntnn ssapwrlgnt qataplatlm imtllllplt plaqtltn
```

nceptos BD Biológicas Acceso Tipos

### Campos Esenciales en un registro de una BD biológica

- ► La secuencia
- ► El número de acceso o *Accession Number* (AC)
- Datos taxonómicos
- Referencias
- Palabras clave (keywords)
- Documentación/ Anotaciones/Curación (curation)
  - ► Grupos de investigación (sumisión directa)
  - ▶ información literatura sumplementaria
  - Intitutos de secuenciación
  - Patentes



# El Formato de los registros necesita ser consistente dentro de la BD

Un entrada en la BD de proteínas SwissProt en formato FASTA:

>sp|P01588|EP0\_HUMAN Erythropoietin OS=Homo sapiens OX=9606 GN=EP0 PE=1 SV=1

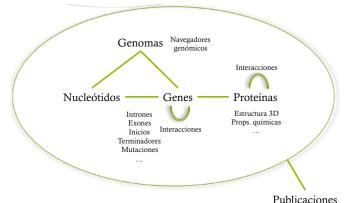
MGVHECPAWLWLLLSLLSLPLGLPVLGAPPRLICDSRVLERYLLEAKEAENITTGCAE HCSLNENITVPDTKVNFYAWKRMEVGQQAVEVWQGLALLSEAVLRGQALLVNSSQ PWEPLQLHVDKAVSGLRSLTTLLRALGAQKEAISPPDAASAAPLRTITADTFRKLFRV YSNFLRGKLKLYTGFACRTGDR



onceptos BD Biológicas Acceso Tipos

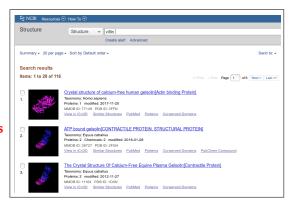
## Importancia de las BDs Biológicas?

- ► El propósito de estas BD va más allá de simplemente almacenar datos de forma organizada.
- ► Se buscá también permitir una recuperación de datos **inteligente**.



# Recuperación de Información a travéz de Consultas o Queries

- Un query o consulta es el método para recuperar información de la BD.
- Especialmente las consultas sobre los campos, debido a la organización de los registros con base a campos.



## Tipos de BDs Biológicas

### Tipos de BDs Biológicas

- ► BDs Primarias
- ► BDs Secundarias
- ► BDs Especializadas

#### **BDs Primarias**

- ► Contienen datos biológicos originales
- Secuencias crudas o datos estructurales sometidos por la comunidad científica
- ► Estas son:
  - GenBank: mantenida por el NCBI (National Center for Biotechnology Information)
  - ► EMBL: mantenida por el EBI (European Bioinformatics Institure)
  - DDBJ: DNA Database of Japan
  - PDB: Protein Data Bank mantenida por el RCSB (Research Collaboratory for Structural Bioinformatics)

#### BDs Secundarias

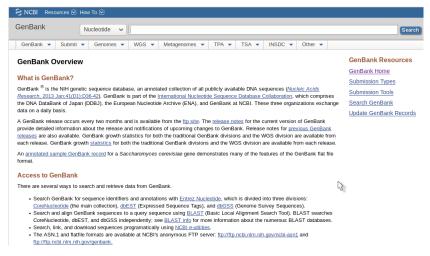
- ► Las BD secundarias contienen información procesada computacional o manualmente por un experto, a partir de información original de las bases de datos primarias
- ► Las BD de secuencias traducidas de proteínas que contienen anotaciones funcionales pertenecen a esta categoría
- ► Algunos ejemplos son:
  - UniProt: un recurso completo, de alta calidad y de libre acceso de secuencias proteicas e información funcional
  - ► PIR (Protein Information Resources) que es sucesor del Atlas of Protein Sequence and Structure

### BDs Especializadas

- ► Las BD especializadas son aquellas dedicadas un interés de investigación particular
- ► Por ejemplo:
  - ► Flybase: Una BD de genes y genomas de Drosófila
  - ► HIV sequence database,
  - ► Ribosomal Database Project
    - ► ..

#### BD GenBank:

#### https://www.ncbi.nlm.nih.gov/genbank/



#### **BD EMBL-EBI:**

https://www.ebi.ac.uk/



#### We are EMBL-EBI

The European Bioinformatics Institute (EMBL-EBI) is part of EMBL, Europe's flagship laboratory for the life sciences. More about EMBL-EBI and our impact. >

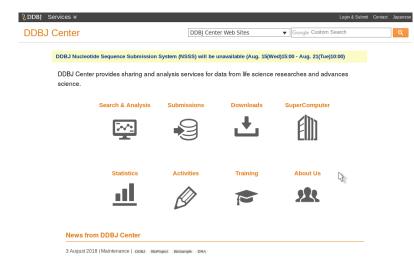
#### Data resources

Explore our open data resources to enrich your research. Browse data, perform analyses or share your own results. >

#### Research

Find out about our research groups, postdoctoral schemes and PhD Programme >

#### DDBJ: https://www.ddbj.nig.ac.jp



BD Biológicas Tipos

#### PDB:



Deposit

Q Search

✓ Visualize

**##** Analyze

♠ Download

Learn

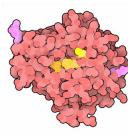
the 3D shapes of proteins, nucleic acids, and complex assemblies that helps students and researchers understand all aspects of biomedicine and agriculture, from protein synthesis to health and disease.

As a member of the wwPDB, the RCSB PDB curates and annotates RDB data.

The RCSB PDB builds upon the data by creating tools and resources for research and education in molecular biology, structural biology, computational biology, and beyond.

Award-Winning Videos on Antibiotic Resistance





#### Ejercicio: Realizar búsquedas en todas las BD primarias

#### Buscar los términos:

#### "early-onset breast cancer human brca2"

► BRCA2 y BRCA2 son el gen y su proteína, respectivamente para el gen relacionado con el cancer de mama.

► Completa, pero fácil de realizar búsquedas

- ► Completa, pero fácil de realizar búsquedas
- ► Anotada, pero no "demasiado anotada"

- ► Completa, pero fácil de realizar búsquedas
- ► Anotada, pero no "demasiado anotada"
- ► Simple y fácil de entender su estructura



- ► Completa, pero fácil de realizar búsquedas
- ► Anotada, pero no "demasiado anotada"
- ► Simple y fácil de entender su estructura
- ► Con referencias cruzadas (*cross-referenced*)

- ► Completa, pero fácil de realizar búsquedas
- Anotada, pero no "demasiado anotada"
- Simple y fácil de entender su estructura
- ► Con referencias cruzadas (*cross-referenced*)
- ► Redundancia mínima

- ► Completa, pero fácil de realizar búsquedas
- Anotada, pero no "demasiado anotada"
- Simple y fácil de entender su estructura
- ► Con referencias cruzadas (*cross-referenced*)
- Redundancia mínima
- ► Fácil recuperación de los datos

- ► Completa, pero fácil de realizar búsquedas
- Anotada, pero no "demasiado anotada"
- Simple y fácil de entender su estructura
- ► Con referencias cruzadas (*cross-referenced*)
- Redundancia mínima
- ► Fácil recuperación de los datos

### Problemas con las BD Generales (Primarias)

BDs que se esfuerzan por una "amplitud enciclopédica" son demasiado grandes y se vuelven inmanejables:

- ► Propensas a ser bastante redundantes
- ► Secuencias inadecuadas:
  - Viejas
  - ► Parcialmente anotadas
  - Inconsistentes y anotaciones viejas
  - Secuencias con errores o de baja calidad
  - Contaminaciones
  - Secuencias anónimas