# BLAST: Búsquedas en Bases de Datos de Secuencias

Luis E. Garreta U luis.garreta@javerianacali.edu.co

Curso de Bioinformática Pontificia Universidad Javeriana – Cali Facultad de Ingeniería - Carrera de Biología

8 de septiembre de 2018



# **Objetivos**

- ► Descubrir porque las búsquedas de similaridades son tan importantes
- ► Entender la relación entre homología, similaridad, e "identidad"
- ► Ejecutar BLAST e interpretar las salidas
- ► Entender el concepto de *e-values*
- ► Conocer cómo hacer preguntas biológicas con BLAST

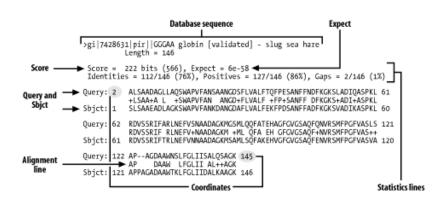
#### Plan

- ► Significado biológico de similaridad entre secuencias
- ► Homología, identidad, y similaridad
- ► Ejecución de BLAST
- ► Interpretación de la salida de BLAST
- Análisis biológicos con BLAST
- ► Ejecución de PSI-BLAST

#### Similaridad entre Secuencias

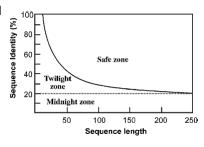
- ▶ Dos secuencias de proteínas con más del 25 % de aminoácidos identicos (sobre 100 AA) son homologas.
- ▶ Dos secuencias de ADN con más del 70 % de nucleótidos idénticos (sobre 100 NN) son homologas.
- ► Secuencias homologas tienen:
  - ► Un ancestro común (proteínas y ADN)
  - ► Una estructura 3D similar (proteínas)
  - ► A menudo una función similar (proteínas)

#### Alineamientos



# Homología

- ► Cuando dos proteínas tienen menos que el 25 % de identidad
  - ► Pueden ser o no homologos
  - Es imposible decir que es verdad
- Este rango de identidad es llamado:
  - ► "la zona de penumbra"
  - ► "Twilight Zone"



# Homología, Similaridad, e Identidad

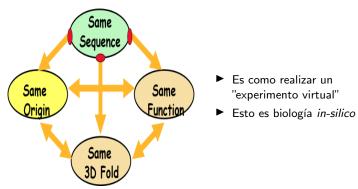
- ► Identidad es una medida realizada sobre el alineamiento
  - ► Secuencia A puede ser "32 % identica" a la secuencia B
- ► Similaridad es una medida de que tan cerca están dos aminoácidos:
  - ► Por ejemplo, isoleucina y leucina son similares
- ► Homología es una propiedad que existe o no
  - ► Secuencia A ES o NO ES homologa a la secuencia B
  - ► Secuencia A **no puede** ser 40 % homologa a B
- Homología se establece con base en la similaridad e identidad medidas

## Cómo Establecer Homología

- Comparar proteína A con cada proteína en una base de datos (e.g. Swiss-Prot)
- ► Identificar una Proteína B que es 40 % identica a su proteína
  - Es mejor usar el *e-value* pero la idea es la misma (...)
- ► Se puede concluir que A y B son probablemente homólogos si ambas son muy similares
  - Es como decir, "Juan y María son probablemente hermanos ya que ellos son muy similares"
- ► Entonces, si se conoce la estructura o función de B, entonces A y B probablemente tienen la misma estructura.

# Biología *In-silico*

Cuando ya se logra establecer que dos proteínas (A y B) son homologas, entonces se puede extrapolar todo lo que conoce de la proteína A hacia la proteína B:



#### **BLAST**

- ► BLAST: Basic Local Alignment Search Tool
- ► BLAST es una herramienta para comparar una secuencia con TODAS las otras secuencias dentro de una base de datos
- ► BLAST puede comparar:
  - ► Secuencias de ADN
  - Secuencias de Proteínas
- BLAST es más exacto al comparar secuencias de proteínas que al comparar secuencias de ADN

# BLAST (continuación)

- ► BLAST realiza alineamientos locales:
  - ► Solamente alinea lo que puede ser alineado
  - ► e ignora el resto
- ► BLAST es muy rápido
  - Sólo unos pocos segundos para explorar la BD Swiss-Prot en un PC estándar

Existen varios sabores de BLAST para realizar diferentes tareas:



## BLASTing de una Secuencia de Proteínas

► Seleccione el tipo de BLAST correcto para proteínas

#### Qué es lo que quiero hacer?

- Quiero encontrar algo acerca de la función de mi proteína blastp, para compara su proteína con otras contenidas en BDs de proteínas
- Quiero descubrir nuevos genes que codifican proteínas: tblastn, para comparar su proteína con secuencias de ADN trasladadas en los 6 posibles marcos de lectura (3 en cada hebra)

## Ejecución de blastp

1 Ingrese la secuencia a buscar:

Nombre: Ingresar el código o número de acceso (gen o

proteína)

Secuencia: Cortar y pegar la secuencia cruda (ADN o

Aminoácidos)

Seleccione uno de los servidores públicos:

NCBI: www.ncbi.nlm.nih.gov/blast

EBI: www.ebi.ac.uk/blast

 ${\sf EMBnet:}\ www.{\sf expasy.ch/blast}$ 

3 Seleccione la base de datos donde buscar:

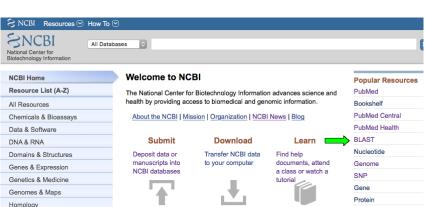
NR para encontrar cualquier secuencia de proteína Swiss-Prot para encontrar proteínas con funciones conocidas PDB para encontrar proteínas con estructuras 3D conocidas

4 Ejecute BLAST dando click en el botón BLAST



# Ejercicio 1: BLASTING Blast para una secuencia de nucleótidos desconocida

- Descargue la secuencia desconocida del github
- ► Ejecute BLAST sobre esta secuencia



#### Develop

Use NCBI APIs and code libraries to build applications



#### Analyze

Identify an NCBI tool for your data analysis task



PubChem

#### Research

Explore NCBI research and collaborative projects



Literature Proteins Sequence Analysis

Taxonomy

Variation

Training & Tutorials



NCBI

Recent Results

Saved Strategies

Help

Sign in to NCBI

# Basic Local Alignment Search Tool

**BLAST** finds regions of similarity between biological sequences. The program compares nucleotide or protein sequences to sequence databases and calculates the statistical significance.

Learn more

#### BLAST+ 2.4.0 released

Home

A new version (2.4.0) of the BLAST+ executables is now available.

Thu, 02 Jun 2016 14:00:00 EST More BLAST news...

#### Web BLAST

**BLAST**®



#### blastx

translated nucleotide > protein

tblastn

protein ▶ translated nucleotide



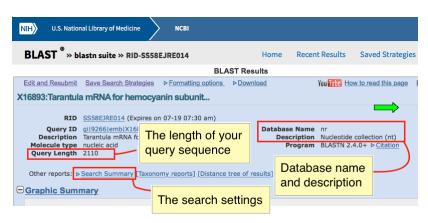
Enter accession n	umber(s), gi(s), or FASTA sequence(s) 🥹	Clear	Query subrange		
GAATCGGAGAGTG ACGACAAGCAGG CAGTTCCTGCAGA	S893.1  Tarantula mRNA for hemocyanin subunit a STTGGTCACTTACCGCGGGGAACATCGAGCAATTCCA TTCAGGCACTGAAGTTGTTCGAGAAGCTCAGCGTAGC CCAGATCGACGAAAGGCTTAGAACATCACAACCTT. ACCCAGACCACTTGGAACAAGCCAAGAGAGTCTACGA	CGCCACTGGTGAGC AGGTCCCAATGAATC	То		
Or, upload file Job Title	Choose File no file selected				
☐ Align two or mo	re sequences 🚇				
Choose Searc	h Set				
Database	Human genomic + transcript  Mouse genomic + transcript  Others (nr etc.):  Nucleotide collection (nr/nt)				
Organism Optional	Enter organism common name, binomial, or tax id. Only 20 top taxa will be shown @				
Exclude Optional	☐ Models (XM/XP) ☐ Uncultured/environmental sample sequences				
Limit to Optional Entrez Query Optional	Sequences from type material  You to Create custom database  Enter an Entrez query to limit search &				
Program Sele	ction				
Optimize for	Highly similar sequences (megablast)  More dissimilar sequences (discontiguous megablast)				
	Somewhat similar sequences (blastn) Choose a BLAST algorithm	•	last to find the best equence or change to		
BLAST	Search database Nucleotide collection (nr/nt) u	blastn to find related sequences from other organisms			

#### Lectura de los resultados de BLAST:

- ► Graphic Display:
  - Vista Gráficos de los alineamientos
- ► Hit List:
  - Descripción de los alineamientos
- ► Alignments:
  - ► Detalle de los alineamientos

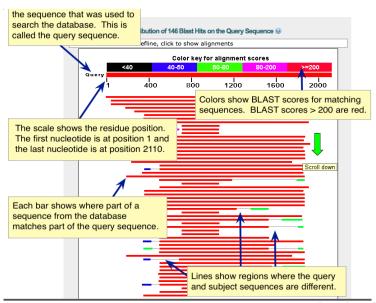


# Resultados: Search Summary

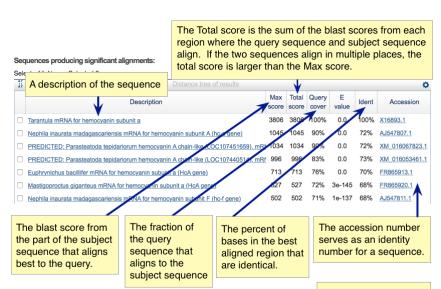


Copyright © 2016 Digital World Biology LLC All rights reserved.

#### Resultados: Vista Gráfica



#### Resultados: Lista de Hits



# Results: e-values o valor esperado

The E (Expect) value is equal to the number of matching sequences you would expect to find if you searched a database of random sequences.

Two important parameters that influence the E value are:

The number sequences in the database
The length of the query sequence

The E value increases when the database is larger and / or the query sequence is shorter. Both of these changes increase the probability of finding a matching sequence.

If the E value is close to zero, the program rounds the value off to zero.

The letter "e" in the number means exponent.

0.86

In this example, the E value equals

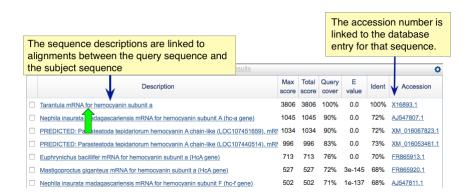
1 x 10 -21

An E value this low corresponds to a very low chance of finding a random sequence that matches this well.

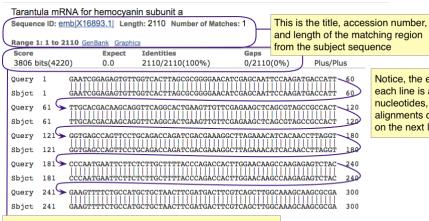
This sequence has an E value of 3.4. That means you would expect to find 3.4 sequences in a random database that match the query as well as this one.



## Results: Descripciones de las Secuencias Hits



#### Results: Detalle de los Alineamientos



In this alignment the raw blast score is 4420 (about twice the number of nucleotides), the E value is 0.0. All 2110 aligned bases are identical and there aren't any gaps.

Notice, the end

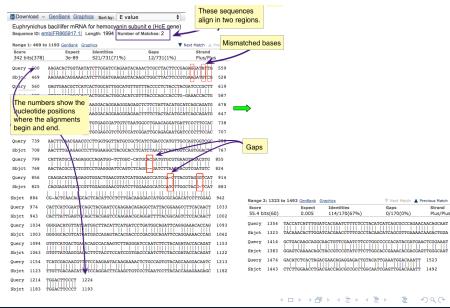
each line is at 6

nucleotides, bu

alignments con

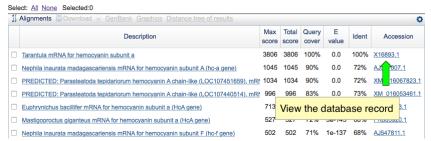
on the next line

## Results: Otro alineamiento con dos matches



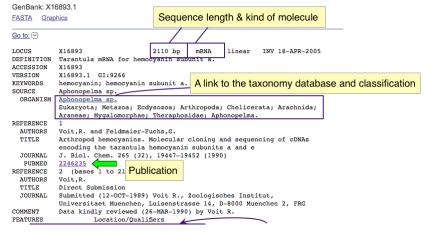
## Results: Registro de la Base de Datos

#### Sequences producing significant alignments:

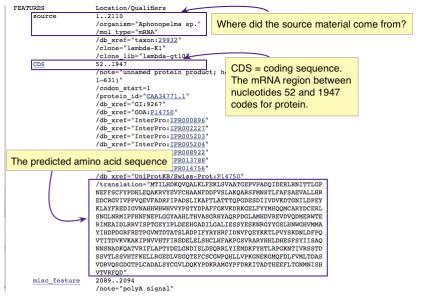


## Results: Encabezado Registro de la Base de Datos

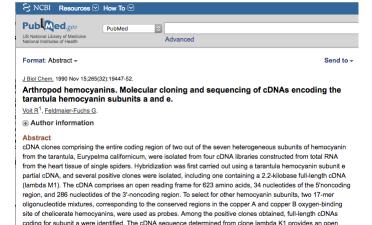
#### Tarantula mRNA for hemocyanin subunit a



# Results: Features Registro de la Base de Datos



#### Results: Publicación



reading frame coding for 630 amino acids and includes the 5"- and 3"-noncoding regions. Northern blot analysis revealed single transcripts for subunits a and e, each 2.3 kilobases long. The cDNAs for subunits a and e were both found to lack any leader pectide sequence. This supports the idea that the mature protein accumulation

cytoplasm and is released by cell rupture.

#### Los *E-Values*

- ► E-value significa valor experado (*expecta*)
- E-value es la medida más usada para estimar similaridad entre secuencias
- ► Cuantas veces es puedo encontrar al azar un alineamiento igual
- ► Si un alineamiento es altamente inexperado, este problemente no se dará solo por azar
  - ► Origin común es la explicación más probable
  - Es así como se infiere homología

## Qué valores son aceptables para los *E-values*

- ► Bajo e-value **implica** un buen hit
  - ► 1 = bad e-Value
  - ► 10e-3 = borderline E-value
  - ► 10e-4 = good E-value
  - ▶ 10e-10 = very good E-value
- ► E-values menores que 10e-4 indican posible homología
- ► E-values más altos que10e-4 requierne evidencia extra evidence para soportar la homología

#### Porqué usar e-values

- e-values hacen posible comparar alineamientos de diferentes longitudes
- e-values son usados por la mayoría de programas de comparación de secuencias
  - ► BLAST
  - ► FASTA
  - ► PSI-BLAST
  - ▶ ..

## **BLASTing Secuencias de ADN**

- ► Secuencias de ADN:
  - ► ADN codificante
  - ► ADN no-codificante
- ▶ BLASTing de secuencias de ADN es menos exacto que realizar BLAST con secuencias de proteínas

# **BLASTing Secuencias de ADN**

Program	Query	Database
blastn	nucleotide	nucleotide
blastx	nucleotide protein	vs protein
tblastx	nucleotide protein	nucleotide vs protein

## Ejercicio2: Realizar el BLAST de la proteína P09405